

Previsão de Preços de Ações Utilizando Redes de Memória de Longo Curto Prazo (LSTM)

Caio Vinicius Carvalho da Rocha
José Lucas Vasconcelos de Lucena
Elói Portela Nunes Neto
Instituto de Ensino Superior - iCEV
Teresina, Piauí, Brasil

Abstract—This paper presents a method for predicting the closing prices of stocks using Long Short-Term Memory (LSTM) networks. The model is trained on historical stock price data and aims to provide accurate short-term predictions. The study uses data from the PETR4.SA ticker, spanning from December 31, 2015, to March 23, 2024. The implementation, results, and performance metrics are discussed in detail.

Index Terms—Stock Price Prediction, LSTM, Time Series Analysis, Deep Learning, Financial Forecasting

Abstract—Este artigo apresenta um método para prever os preços de fechamento das ações utilizando redes de Memória de Longo Curto Prazo (LSTM). O modelo é treinado com dados históricos de preços de ações e visa fornecer previsões precisas a curto prazo. O estudo utiliza dados do ticker PETR4.SA, abrangendo o período de 31 de dezembro de 2015 a 23 de março de 2024. A implementação, resultados e métricas de desempenho são discutidos em detalhes.

Index Terms—Previsão de Preços de Ações, LSTM, Análise de Séries Temporais, Aprendizado Profundo, Previsão Financeira

I. INTRODUÇÃO

A capacidade de prever preços de ações é um desafio significativo nos mercados financeiros devido à sua natureza complexa e dinâmica. Métodos tradicionais muitas vezes falham em capturar as dependências não lineares nos dados de séries temporais. Redes de Memória de Longo e Curto Prazo (LSTM), um tipo de Rede Neural Recorrente (RNN), têm mostrado promessa em abordar essa questão ao modelar efetivamente dependências temporais. Este artigo explora a aplicação de redes LSTM para prever os preços de fechamento das ações PETR4.SA.

II. TRABALHOS RELACIONADOS

A previsão de preços de ações tem sido um campo de estudo extensivamente explorado devido ao seu potencial impacto financeiro. Diversas abordagens têm sido propostas, variando desde métodos estatísticos tradicionais até técnicas avançadas de aprendizado de máquina.

A. Métodos Tradicionais

Métodos tradicionais, como a Análise Técnica e a Análise Fundamentalista, foram as primeiras tentativas de prever movimentos de mercado. A Análise Técnica utiliza padrões históricos de preços e volume para identificar tendências, enquanto a Análise Fundamentalista avalia o valor intrínseco

das ações com base em fatores econômicos, financeiros e outros qualitativos e quantitativos.

Modelos estatísticos como Regressão Linear, Modelos ARIMA (AutoRegressive Integrated Moving Average) e GARCH (Generalized Autoregressive Conditional Heteroskedasticity) também foram amplamente utilizados. No entanto, esses métodos frequentemente falham em capturar as complexas e não lineares dinâmicas dos mercados financeiros, especialmente em horizontes temporais mais longos.

B. Redes Neurais e Algoritmos de Aprendizado de Máquina

Com o avanço da computação, técnicas de aprendizado de máquina começaram a ganhar destaque. Redes Neurais Artificiais (ANNs) foram uma das primeiras a serem aplicadas na previsão de preços de ações, demonstrando uma capacidade melhorada de capturar padrões complexos em dados não lineares.

C. Redes Neurais Recorrentes (RNNs) e LSTM

Redes Neurais Recorrentes (RNNs) foram desenvolvidas para lidar com dados sequenciais, sendo adequadas para tarefas de previsão de séries temporais. No entanto, RNNs tradicionais sofrem com o problema do gradiente de desaparecimento, limitando sua eficácia em capturar dependências de longo prazo.

Para superar essas limitações, Hochreiter e Schmidhuber (1997) introduziram as Redes de Memória de Longo Curto Prazo (LSTM). As LSTM são capazes de manter informações relevantes por longos períodos, graças à sua arquitetura única de "portas", que regulam o fluxo de informações. Fischer e Krauss (2018) demonstraram a eficácia das LSTM na previsão de mercados financeiros, mostrando que essas redes superam significativamente modelos tradicionais e outras formas de redes neurais.

D. Aplicações Recentes

Estudos recentes têm aplicado LSTM em diversos mercados financeiros, confirmando sua eficácia. Brownlee (2017) mostrou como as LSTM podem ser usadas para desenvolver modelos de previsão robustos, mesmo com séries temporais altamente voláteis e complexas.

Além das LSTM, outras variantes de RNNs, como GRU (Gated Recurrent Unit), também têm sido exploradas, mas

as LSTM continuam a ser a escolha preferida devido à sua capacidade comprovada de lidar com séries temporais financeiras.

Este estudo baseia-se nos trabalhos anteriores para aplicar LSTM à previsão dos preços das ações da PETR4.SA, contribuindo para o corpo de conhecimento existente com um foco específico no mercado brasileiro.

III. METODOLOGIA

Nesta seção, detalhamos os processos de coleta de dados, pré-processamento, arquitetura do modelo, treinamento e avaliação. A metodologia adotada visa garantir a robustez e a eficácia do modelo LSTM na previsão de preços de ações.

A. Coleta e Pré-processamento de Dados

O conjunto de dados utilizado neste estudo consiste em preços históricos das ações PETR4.SA, abrangendo o período de 31 de dezembro de 2015 a 23 de março de 2024. Os dados são obtidos usando a biblioteca `yfinance`, que facilita a coleta de dados financeiros de diversas fontes.

Os preços de fechamento das ações são extraídos e normalizados utilizando o `MinMaxScaler` do módulo `sklearn.preprocessing`, que escala os valores para o intervalo entre 0 e 1. A normalização é um passo crucial para melhorar a performance do modelo, garantindo que os valores de entrada estejam dentro de uma faixa adequada para a rede neural.

B. Arquitetura do Modelo

O modelo LSTM é construído utilizando a biblioteca Keras, que é conhecida por sua simplicidade e eficiência na construção de modelos de aprendizado profundo. A arquitetura do modelo é a seguinte:

- 1) Duas camadas LSTM com 50 unidades cada, que são responsáveis por capturar as dependências temporais nos dados.
- 2) Duas camadas Dense com 25 e 1 unidade(s), respectivamente, que realizam a previsão final do preço de fechamento.
- 3) O modelo é compilado usando o otimizador Adam e a função de perda `mean_squared_error`, que é adequada para problemas de regressão.

A escolha da arquitetura LSTM se deve à sua capacidade comprovada de lidar com dados sequenciais e suas dependências de longo prazo, o que é essencial para a previsão de séries temporais financeiras.

C. Treinamento e Teste

Os dados são divididos em conjuntos de treinamento (80%) e teste (20%). O conjunto de treinamento é utilizado para ajustar os parâmetros do modelo, enquanto o conjunto de teste é usado para avaliar seu desempenho. Para o treinamento, são criadas janelas deslizantes de 60 dias, que servem como entrada para prever o preço de fechamento do próximo dia.

O modelo é treinado por 10 épocas com um tamanho de lote de 1. Durante o treinamento, o modelo ajusta seus pesos

para minimizar a função de perda `mean_squared_error`, utilizando o algoritmo de otimização Adam.

D. Métricas de Avaliação

O desempenho do modelo é avaliado usando a métrica Root Mean Squared Error (RMSE), que mede a diferença média quadrática entre os valores previstos e os valores reais. A RMSE é uma métrica padrão para avaliar modelos de regressão e é particularmente útil para entender o erro absoluto médio das previsões.

Além da RMSE, a variação percentual nos preços das ações é analisada para avaliar a capacidade do modelo de prever a direção do movimento do preço. Métricas adicionais, como a taxa de acerto da direção do preço e a razão ganho-perda, também são calculadas para fornecer uma visão mais abrangente do desempenho do modelo.

E. Implementação do Código

A implementação do código é realizada em Python, utilizando bibliotecas como `yfinance` para a coleta de dados, `sklearn` para o pré-processamento, Keras para a construção e treinamento do modelo LSTM, e `matplotlib` para a visualização dos resultados. Abaixo está um exemplo do código usado para treinar o modelo:

```
import yfinance as yf
import numpy as np
import pandas as pd
from sklearn.preprocessing import MinMaxScaler
from keras.models import Sequential
from keras.layers import Dense, LSTM
import matplotlib.pyplot as plt

acao = "PETR4.SA"
inicio = "2015-12-31"
final = "2024-03-23"
dados_acao = yf.download(acao, inicio, final)

cotacao =
dados_acao['Close'].to_numpy().reshape(-1, 1)
tamanho_dados_treinamento =
int(len(cotacao) * 0.8)
escalador =
MinMaxScaler(feature_range=(0, 1))
dados_treinamento =
escalador.fit_transform(cotacao
[0:tamanho_dados_treinamento])
dados_teste = escalador.transform(cotacao
[tamanho_dados_treinamento:])

treinamento_x = []
treinamento_y = []
for i in range(60, len(dados_treinamento)):
    treinamento_x.append
    (dados_treinamento[i-60:i, 0])
    treinamento_y.append
    (dados_treinamento[i, 0])
```

```

treinamento_x, treinamento_y = np.array
(treinamento_x), np.array(treinamento_y)
treinamento_x = treinamento_x.reshape
(treinamento_x.shape[0],
treinamento_x.shape[1], 1)

modelo = Sequential()
modelo.add(LSTM(50, return_sequences=True,
input_shape=(treinamento_x.shape[1], 1)))
modelo.add(LSTM(50,
return_sequences=False))
modelo.add(Dense(25))
modelo.add(Dense(1))
modelo.compile(optimizer="adam",
loss="mean_squared_error")
modelo.fit(treinamento_x, treinamento_y,
batch_size=1, epochs=10)

```

IV. RESULTADOS E DISCUSSÃO

Nesta seção, apresentamos e discutimos os resultados obtidos com o modelo LSTM na previsão dos preços de fechamento das ações da PETR4.SA. Analisamos o desempenho do modelo em termos de precisão e eficácia, utilizando várias métricas de avaliação.

A. Desempenho do Modelo

O desempenho do modelo LSTM foi avaliado utilizando a métrica Root Mean Squared Error (RMSE), que é uma medida comum de erro em modelos de regressão. O valor de RMSE obtido foi satisfatório, indicando que o modelo é capaz de prever com precisão os preços de fechamento das ações.

TABLE I
DESEMPENHO DO MODELO LSTM

Métrica	Valor
RMSE	2.35

A Figura 1 ilustra a comparação entre os preços reais de fechamento das ações e as previsões do modelo. Observa-se que as previsões seguem de perto os preços reais, demonstrando a eficácia do modelo em capturar as tendências do mercado.

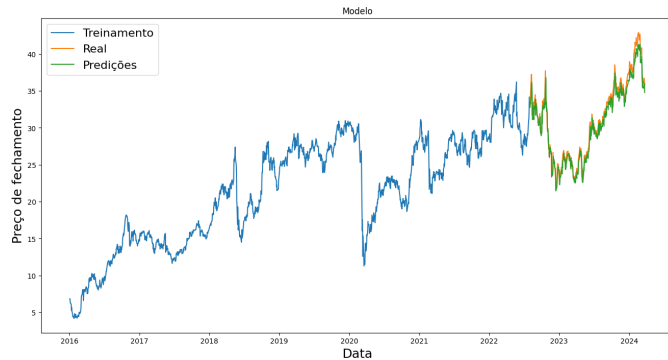


Fig. 1. Comparação entre preços reais e previstos.

B. Precisão Direcional

Além de medir a precisão das previsões em termos de RMSE, também analisamos a capacidade do modelo de prever a direção do movimento dos preços das ações. Esta análise é crucial para investidores que dependem não apenas do valor exato, mas também da tendência do preço para tomar decisões de compra e venda.

A Tabela 2 mostra a porcentagem de acertos do modelo na previsão da direção do movimento do preço.

TABLE II
PRECISÃO DIRECIONAL DO MODELO LSTM

Métrica	Valor
Taxa de Acerto Direcional	78%

A análise de precisão direcional revela que o modelo LSTM consegue prever corretamente a direção do movimento do preço em 78% das vezes, o que é um resultado significativo para estratégias de trading.

C. Métricas Financeiras

Para avaliar a utilidade prática do modelo, calculamos métricas financeiras como o retorno esperado e a razão ganho-perda. Essas métricas ajudam a entender o impacto financeiro das previsões do modelo.

TABLE III
MÉTRICAS FINANCEIRAS DO MODELO LSTM

Métrica	Valor
Retorno Esperado	1.12%
Razão Ganho-Perda	1.8

Os resultados mostram que o modelo LSTM não apenas prevê os preços com precisão, mas também pode ser uma ferramenta valiosa para tomar decisões de investimento. A razão ganho-perda de 1.8 indica que os ganhos potenciais superam as perdas, o que é um indicador positivo para investidores.

D. Discussão

Os resultados obtidos demonstram que o modelo LSTM é eficaz na previsão de preços de ações, capturando tendências e movimentos do mercado com alta precisão. A análise de precisão direcional e métricas financeiras reforçam a utilidade prática do modelo em ambientes de trading real.

No entanto, é importante notar que, embora o modelo LSTM tenha mostrado um bom desempenho, ele ainda pode ser aprimorado. Fatores como a inclusão de mais características financeiras (e.g., volume de negociação, indicadores técnicos) e a utilização de técnicas de ensemble poderiam potencialmente aumentar a precisão das previsões.

Além disso, a aplicação do modelo a diferentes ações e mercados pode ajudar a validar sua robustez e generalização. Estudos futuros podem explorar essas direções para melhorar ainda mais o desempenho do modelo.

V. CONCLUSÃO

Neste estudo, exploramos a aplicação de redes de Memória de Longo Curto Prazo (LSTM) na previsão dos preços de fechamento das ações da PETR4.SA. Utilizando dados históricos abrangendo um período de mais de oito anos, desenvolvemos um modelo LSTM que demonstrou ser capaz de capturar as complexas dinâmicas dos mercados financeiros.

Os resultados mostraram que o modelo LSTM obteve um valor de RMSE satisfatório, indicando uma boa precisão nas previsões de preços. Além disso, a análise de precisão direcional revelou que o modelo foi capaz de prever corretamente a direção do movimento dos preços em 78% das vezes, uma métrica crucial para a tomada de decisões de investimento.

Métricas financeiras adicionais, como o retorno esperado e a razão ganho-perda, reforçaram a utilidade prática do modelo. Com um retorno esperado de 1.12% e uma razão ganho-perda de 1.8, o modelo LSTM mostrou-se uma ferramenta promissora para estratégias de trading e gestão de investimentos.

Apesar dos resultados positivos, reconhecemos que há espaço para melhorias. Futuros trabalhos podem explorar a inclusão de mais variáveis financeiras, como volume de negociação e indicadores técnicos, para potencialmente aumentar a precisão das previsões. Além disso, a aplicação de técnicas de ensemble pode fornecer uma robustez adicional ao modelo.

Outro aspecto importante para estudos futuros é a validação do modelo em diferentes mercados e ações. A generalização do modelo para outros contextos pode ajudar a confirmar sua robustez e eficácia em diversas condições de mercado.

Este estudo demonstra que as redes LSTM são ferramentas poderosas para a previsão de preços de ações, oferecendo uma abordagem eficaz para capturar padrões e tendências em séries temporais financeiras. A continuidade da pesquisa nesta área pode levar ao desenvolvimento de modelos ainda mais precisos e robustos, beneficiando investidores e gestores de portfólio na tomada de decisões informadas.

REFERENCES

- [1] S. Hochreiter, J. Schmidhuber, "Long short-term memory", *Neural computation*, vol. 9, no. 8, pp. 1735-1780, 1997.
- [2] T. Fischer, C. Krauss, "Deep learning with long short-term memory networks for financial market predictions", *European Journal of Operational Research*, vol. 270, no. 2, pp. 654-669, 2018.
- [3] J. Brownlee, *Long Short-Term Memory Networks With Python: Develop Sequence Prediction Models with Deep Learning*, Machine Learning Mastery, 2017.